



## 110 实验室前沿技术分组研究与专题汇报开题报告

|               |                                                       |            |                 |
|---------------|-------------------------------------------------------|------------|-----------------|
| 研究题目          | 面向复杂文档问答的 Task Graph 驱动 Agentic RAG  workflow 稳定性提升研究 |            |                 |
| 课题类型          | 综合应用类                                                 |            |                 |
| 应用场景与<br>演示方式 | 知识学习助手验证场景；录屏演示与实验数据对比                                | 指导教师/带教学长  | 陈玮/白洋           |
| 小组成员          | 姓名                                                    | 学号         | 专业              |
| 1             | 凌成                                                    | 2024213810 | 智能科学与技术+数学与应用数学 |
| 2             | 何怀峰                                                   | 2024213814 | 智能科学与技术+数学与应用数学 |
| 3             | 周湘江                                                   | 2024213781 | 智能科学与技术+数学与应用数学 |
| 4             | 雷真欣                                                   | 2024214969 | 机械设计制造及其自动化     |



## 一、课题研究目的和意义

随着大语言模型和多模态大模型的发展，面向 PDF 教材、课程 PPT、实验报告、课堂讲义和技术资料等复杂学习文档的智能问答，逐渐成为 AI 教育与知识管理中的重要研究方向。与普通网页文本或单一知识库不同，学习资料往往具有明显的结构复杂性和表达多样性：同一知识点可能分散在章节标题、正文段落、页面截图、流程图、图注、实验数据表格以及跨页说明之中。学生在复习、预习和查阅资料时提出的问题，也不再局限于简单事实查询，而是常常具有跨页定位、跨文档综合、证据比较和结论归纳等特点，例如根据教材解释核心概念、根据 PPT 页面说明实验流程、根据实验报告表格比较数据变化，或综合多份资料形成复习结论。因此，面向学习场景的智能助手不仅要能够生成通顺答案，更需要稳定地找到与问题真正相关的证据，给出可追溯的引用来源，并在证据不足或文档中不存在答案时避免盲目生成。

传统学习助手多集中于通用对话、搜题答疑、单文档摘要或前端交互实现，容易停留在应用层功能搭建，对复杂文档内部结构、证据链条和可复现执行过程关注不足。普通 RAG 虽然能够通过外部知识库增强回答的事实依据，但其流程通常固定为“文本切分、向量检索、上下文拼接、答案生成”，检索策略和答案生成之间缺少明确的中间验证环节。当问题需要识别页面版式、结合表格字段、比较多个证据片段或判断证据是否充分时，普通 RAG 容易出现检索路径单一、图表和页面信息利用不足、错误证据进入最终回答、引用位置不准确、多次运行结果不一致等问题。这些问题会直接影响学习助手的可信度，使学生难以判断答案是否真正来自原始资料。

基于上述问题，本课题将研究范围收缩为“Task Graph 对复杂文档问答 workflow 稳定性的提升研究”。课题以学习助手作为应用验证场景，但核心研究对象不是完整知识助手产品，也不是单纯追求更复杂的前端功能，而是研究 Task Graph 如何约束复杂文档问答中的检索、证据判断、局部修复与答案生成流程。系统将一次问答过程拆解为问题理解、任务路由、文本检索、页面图像检索、简单表格检索、证据充分性验证、局部重检、答案生成和引用校验等可追踪节点，并为不同节点设置清晰的输入、输出、执行条件和失败处理方式。通过这种任务图驱动的方式，Agent 不再完全依赖自由规划和隐式推理，而是在预先定义的工作流约束下完成任务，从而减少执行路径漂移、证据误用和重复运行结果不一致等不稳定现象。

本课题拟明确“稳定性”的量化定义，并围绕任务完成率、路由准确率、引用准确率、证据召回率、失败恢复率、多次运行一致性和抗干扰能力等指标展开实验验证。通过构建固定实验对照组，在同一批复杂学习文档、同一套测试问题和同一评价标准下，比较常规 RAG、常



规 Agentic RAG 与 Task Graph 驱动 Agentic RAG 的表现。实验将重点观察 Task Graph 是否能够降低错误检索和错误引用的概率，是否能够在局部证据不足时通过重检机制恢复任务，以及是否能够在多次运行和干扰文档加入后保持较稳定的回答质量，从而分析其对工作流可控性、可解释性和鲁棒性的提升作用。

本课题的研究意义主要体现在三个方面：

其一，应用层面，能够为复杂学习资料问答、课程复习、图表解释和跨文档资料检索提供更可信的学习助手能力。通过明确证据来源和引用位置，学生可以根据答案回到原文核查依据，教师也可以将其作为辅助答疑、资料整理和课程知识管理工具；

其二，技术层面，通过任务图约束、节点级证据验证和局部重检机制，推动 RAG 从一次性检索生成流程走向可追踪、可验证、可修复的复杂文档问答工作流。该思路有助于减少 Agentic RAG 中自由调用工具带来的路径不确定性，使系统能够记录每一步为什么执行、使用了哪些证据以及失败后如何恢复；

其三，评测层面，围绕稳定性建立可操作指标，为比较普通 RAG 与 Agentic RAG 在复杂文档场景中的差异提供实验依据。通过任务完成率、路由准确率、引用准确率、失败恢复率和多次运行一致性等指标，可以从结果质量和流程质量两个角度评价系统，而不仅仅依赖主观体验判断。



## 二、研究目标

本课题面向复杂学习文档问答场景，拟研究并实现一种 Task Graph 驱动的 Agentic RAG workflow 稳定性增强方法。研究目标既包括系统原型实现，也包括实验数据集构建、评价指标定义和对照实验分析，力求从方法设计、工程实现和量化评测三个层面验证 Task Graph 对复杂文档问答稳定性的作用。具体目标如下：

1. 构建固定实验对照组，包括常规 RAG、常规 Agentic RAG 和 Task Graph Agentic RAG。三类系统将在相同文档集合、相同问题集、相同模型配置和相同评价指标下运行，避免因数据或参数差异影响实验结论，使最终比较能够更集中地反映 workflow 设计差异。
2. 设计复杂文档问答 Task Graph，将问答流程拆解为问题理解、任务路由、证据检索、证据充分性验证、局部重检、答案生成和引用校验等节点。每个节点记录输入、输出、候选证据、执行状态、失败原因和跳转路径，形成可追踪的问答执行日志，为后续错误分析、消融实验和稳定性评估提供依据。
3. 明确定义 workflow 稳定性的量化指标，重点考察任务完成率、路由准确率、引用准确率、证据召回率、失败恢复率、多次运行一致性和抗干扰能力。通过这些指标分别衡量系统是否完成任务、是否选择正确检索路径、答案是否有可靠证据支撑、失败后能否恢复，以及面对重复运行和噪声文档时是否保持稳定。
4. 保留轻量多模态能力作为复杂文档实验基础，核心处理范围限定为文本段落、页面图像和简单表格。文本段落用于概念解释和事实定位，页面图像用于 PPT 页面、图示和版式相关问题，简单表格用于结构化数据比较；公式 OCR、复杂表格解析、Obsidian 写回和向量数据库增量更新降级为选做扩展，以保证核心研究重点集中在 workflow 稳定性验证上。
5. 构建 80-100 个复杂学习文档问答样本，覆盖纯文本事实问答、图示页面理解、简单表格比较、跨页综合、跨文档检索、无答案问题和干扰文档问题。每个样本人工标注标准答案、支持证据所在文档、证据页码或区域、证据类型以及是否允许拒答，用于完成对比实验、消融实验和稳定性分析。
6. 输出可运行的学习助手验证 Demo，用于展示 Task Graph workflow、检索证据、局部重检过程和带引用答案。Demo 将重点体现系统从问题输入到任务路由、证据检索、证据验证、失败恢复和最终回答生成的完整过程，使评审能够直观看到 Task Graph 对问答过程的约束和解释作用。



### 三、研究内容、技术路线与评价指标

#### (一) 主要研究内容

##### 1. Task Graph 驱动的复杂文档问答 workflow 建模。

将复杂文档问答过程建模为可执行任务图，核心节点包括问题解析节点、任务路由节点、文本检索节点、页面图像检索节点、简单表格检索节点、跨模态证据融合节点、Evidence Gate 节点、答案生成节点和引用校验节点。问题解析节点负责识别问题类型和证据需求，任务路由节点决定调用文本、图像或表格检索路径，证据融合节点将不同来源的候选证据统一组织。每个节点保留输入、输出、证据来源、执行状态、失败原因和跳转结果，便于后续进行稳定性分析和错误定位。

##### 2. 面向稳定性的节点级证据验证机制。

在检索节点之后加入 Evidence Gate（证据充分性判断），判断候选证据是否与问题语义相关、是否足以支持回答、是否来自正确文档页面或表格区域，以及不同证据之间是否存在明显冲突。Evidence Gate 不直接追求生成答案，而是先对证据质量进行筛查和分级：证据充分时进入答案生成，证据部分不足时进入局部重检，证据明显缺失或问题超出文档范围时进入拒答或提示证据不足流程。该机制能够减少错误证据进入最终答案的概率。

##### 3. 局部失败恢复机制。

当某一节点失败时，系统仅针对失败节点进行查询改写、检索范围扩展、相邻页面补充或检索参数调整，而不是重跑整个问答流程。例如页面证据不足时扩展相邻页并补充页面标题、图注等上下文；表格证据不足时优先检索表格标题、表头字段和表格前后说明；文本证据不足时重写检索问题或扩大 BM25 与向量检索的候选范围。局部失败恢复机制能够降低重复执行成本，同时保留已成功节点的结果，使 workflow 更可控。

##### 4. 轻量多模态证据处理。

多模态部分聚焦文本、页面图像和简单表格三类证据。文本证据主要用于概念解释、定义查询、事实定位和跨段落综合；页面图像证据主要用于 PPT 页面、流程图、结构图、图文排版和页面整体含义理解；简单表格证据主要用于结构化数值比较、字段定位和实验结果归纳。为控制课题规模，公式 OCR、复杂跨页表格、Obsidian 写回、向量库增量更新不作为核心实验内容，仅在时间允许时作为扩展模块。

##### 5. 固定对照实验与消融实验。

设置三类固定对照组：常规 RAG、常规 Agentic RAG、Task Graph 驱动的 Agentic RAG。





常规 RAG 作为基础检索生成基线，常规 Agentic RAG 作为具备问题改写和简单工具调用能力的对照系统，Task Graph 驱动的 Agentic RAG 作为本课题核心方法。消融实验包括去掉 Evidence Gate（证据充分性判断）、去掉 Local Retry（局部重检）、去掉页面图像检索、去掉引用校验等，以分析各模块对任务完成率、引用准确率、失败恢复率和多次运行一致性等稳定性指标的贡献。

## （二）关键技术路线

1. 文档处理：使用 PyMuPDF/pdf2image 完成 PDF 页面图片导出，并保留页码、文件名和页面顺序等元信息；使用 PaddleOCR 或文档解析工具抽取正文文本、标题层级、图注和页面内文本块；简单表格优先解析为 Markdown/CSV，并保存表格标题、表头字段和所在页码，便于后续检索和引用。

2. 检索模块：使用 BM25 与向量检索构建 RAG 基线，其中 BM25 用于关键词匹配和术语精确召回，向量检索用于语义相似问题和表达变体召回。向量数据库可选 Qdrant，文本向量模型可选 BGE-M3 或 Qwen Embedding，并统一记录 Top-K 候选证据、相似度分数和证据类型。

3. 页面图像理解：对页面图像、流程图、图示或版式相关问题，先通过文本线索、页面标题和检索结果定位候选页面，再调用 Qwen-VL、InternVL 或同类 VLM 进行页面内容理解。该策略避免对全部页面进行视觉推理造成成本过高，也能使视觉模型的调用更集中于真正可能包含答案的页面。

4. 工作流编排：使用 LangGraph 或等价状态图框架实现 Task Graph、节点状态管理、条件跳转、证据 Gate 和局部重检。工作流中每个节点以结构化状态传递信息，包括问题类型、检索路径、候选证据、Gate 判断结果、重检次数和最终引用，保证系统执行过程可记录、可回放、可分析。

5. 实验记录：使用 SQLite/CSV 记录每个问题的任务路由、检索证据、最终答案、引用位置、节点失败原因和多次运行结果。实验记录将作为后续统计脚本的数据来源，用于计算各项评价指标，并支持对典型成功案例、失败案例和不稳定案例进行复盘分析。

## （三）实验设计

1. 文档规模：选择 5-10 份复杂学习文档，包括教材 PDF、课程 PPT、实验报告、含简单表格的文档和含图示页面的资料。文档将尽量覆盖不同版式和不同信息形态，使测试集既包含普通文本问答，也包含需要结合页面、图示和表格才能回答的问题。



2.问题规模：构建 80-100 个测试问题，覆盖纯文本事实问答、页面图像/流程图问答、简单表格问答、跨页综合问答、跨文档综合问答、无答案问题和干扰文档问题。问题设计将兼顾难度层次，既包含可以由单一证据回答的问题，也包含需要多个证据共同支持的问题。

3.标注内容：每个问题标注标准答案、支持证据所在文档、页码或区域、证据类型、是否允许拒答，并尽量说明证据与答案之间的对应关系。对于无答案或证据不足的问题，将明确标注系统应当拒答或提示无法从文档中确认，避免把猜测性回答误判为正确。

4.重复实验：每个系统对同一问题重复运行 3 次，统计答案结论、引用证据和执行路径的一致性。该实验用于观察同一系统在相同输入下是否会出现检索路径漂移、引用证据变化较大或答案结论前后不一致等现象。

5.干扰实验：向知识库加入无关文档或相似主题文档，比较不同方法在噪声环境下的答案准确率、引用准确率和证据召回率下降幅度。该实验用于检验 Task Graph 与 Evidence Gate 是否能够识别并过滤相似但不相关的证据，从而提升复杂文档问答的抗干扰能力。

#### （四）评价指标

1.任务完成率：完整回答且满足题目要求的问题数 / 总问题数。该指标用于衡量系统能否按照题目要求完成问答任务，包括是否覆盖问题中的关键条件、是否给出必要解释以及是否在需要时提供引用。

2.路由准确率：系统选择的检索路径与人工标注目标路径一致的问题数 / 总问题数。该指标重点考察系统能否正确判断问题应走文本检索、页面图像检索、表格检索或跨模态融合路径。

3.引用准确率：答案引用证据能够真实支持答案结论的引用数 / 总引用数。该指标不仅检查是否给出引用，还检查引用内容与答案结论是否存在直接支撑关系，避免出现“引用存在但证据不相关”的情况。

4.证据召回率 Recall@K：标准证据出现在前 K 个候选证据中的问题数 / 总问题数。该指标用于评价检索模块是否能够将正确证据召回到候选集合中，是后续 Evidence Gate 和答案生成能否成功的基础。

5.失败恢复率：首次证据 Gate 失败后，通过局部重检最终完成任务的问题数 / Gate 失败问题数。该指标用于衡量 Local Retry 是否真正提高系统韧性，能否在首次证据不足时通过有限范围的修复继续完成问答。


6.多次运行一致性：同一问题重复运行 3 次后，答案结论一致的问题数 / 总问题数。除答案结论外，实验还将观察引用证据和任务路由是否保持稳定，以判断 Task Graph 是否减少

了 Agent 自由规划带来的随机波动。

7.拒答准确率：无答案或证据不足问题中，系统正确拒答或提示证据不足的问题数 / 无答案问题数。该指标用于评价系统是否能够识别知识边界，避免在文档证据不足时生成看似合理但缺乏依据的答案。

8.抗干扰能力：加入干扰文档前后答案准确率和引用准确率的下降幅度。下降幅度越小，说明系统在相似主题噪声和无关文档干扰下越能保持正确检索与可靠引用。

9.平均响应时间：系统完成一次问答的端到端平均耗时。该指标用于观察 Task Graph、证据验证和局部重检带来的额外开销，并与答案质量和稳定性提升进行综合权衡。







## 四、小组成员、任务分工与进度安排

### （一）小组分工

**凌成:** Task Graph 工作流与稳定性增强模块负责人。负责任务图节点设计、Evidence Gate、Local Retry、Citation Verify、整体流程集成和关键案例调试，并协调各模块之间的数据格式与状态传递，保证核心工作流能够稳定运行。

**何怀峰:** RAG 基线与检索模块负责人。负责常规 RAG、常规 Agentic RAG 对照组搭建，完成文本检索、页面图像检索、简单表格检索和知识库构建，并整理检索模块的输入输出接口，为 Task Graph 系统提供统一候选证据。

**周湘江:** 评测数据集与实验统计模块负责人。负责复杂文档问题集构建、标准答案与证据标注、评价脚本、重复运行实验、干扰实验和结果表格统计，并对典型成功案例、失败案例和指标变化原因进行归纳分析。

**雷真欣:** 文档资料、汇报材料与演示模块负责人。负责实验文档整理、PPT 制作、开题/结题文档、演示脚本、录屏材料，并协助完成测试问题标注和 Demo 展示素材整理，保证最终汇报能够清晰呈现研究动机、系统流程和实验结果。

### （二）进度安排

**阶段 1 (Day 1-3):** 收缩研究范围，确定题目、对照组、稳定性指标、文档类型和问题分类；明确核心研究边界与选做扩展内容，产出实验方案、评价指标表和系统总体流程草图。

**阶段 2 (Day 4-7):** 整理 5-10 份复杂学习文档，完成文本抽取、页面图片导出、简单表格整理和基础知识库构建；统一文档编号、页码和证据格式，产出可检索文档库及文档处理记录。

**阶段 3 (Day 8-11):** 构建 80-100 个测试问题，标注标准答案、证据页码、证据类型和是否允许拒答；覆盖文本、图像、表格、跨页、跨文档和无答案等类型，产出人工标注测试集和问题分类统计表。

**阶段 4 (Day 12-15):** 实现 RAG 基线，完成 BM25/向量检索、答案生成和引用输出；记录检索候选、模型回答和引用来源，产出基础对照结果与初步错误案例。

**阶段 5 (Day 16-18):** 实现常规 Agentic RAG 对照组，支持问题重写、简单工具调用和多轮检索，但不加入 Task Graph 稳定性约束；与 RAG 基线保持相同数据和评价方式，产出 Agentic RAG 对照结果。

**阶段 6 (Day 19-24):** 实现 Task Graph Agentic RAG 核心流程，包括任务路由、节点



状态记录、Evidence Gate、Local Retry 和 Citation Verify；完成节点间状态传递、条件跳转和失败原因记录，产出核心方法原型。

**阶段 7 (Day 25-27)：**接入轻量多模态节点，完成页面图像检索/理解和简单表格问答；重点验证文本、页面图像和简单表格三类证据在任务图中的协同方式，公式 OCR、复杂表格、Obsidian 写回和向量库增量更新仅作为选做扩展。

**阶段 8 (Day 28-31)：**运行完整对比实验、消融实验、重复运行一致性实验和干扰文档实验；统一保存每次运行的检索证据、节点状态、最终答案、引用来源和耗时，产出原始实验记录。

**阶段 9 (Day 32-33)：**统计任务完成率、路由准确率、引用准确率、证据召回率、失败恢复率、多次运行一致性等指标，整理成功案例、失败案例和典型不稳定案例，分析各模块对指标变化的影响。

**阶段 10 (Day 34-35)：**完成报告、PPT、演示 Demo 和录屏材料，准备答辩说明。最终材料将围绕研究背景、方法设计、系统实现、实验对比、消融分析和结论展开展示。



## 五、预期成果/产出

1. Task Graph 驱动 Agentic RAG 原型系统。系统面向复杂学习文档问答，支持问题分析、任务路由、文本检索、页面图像检索、简单表格检索、证据充分性验证、局部重检、答案生成和引用校验，并能够记录节点执行状态和关键中间结果。

2. 小规模复杂学习文档问答测试集。预计包含 5-10 份复杂学习文档和 80-100 个标注问题，每个问题包含标准答案、证据页码、证据类型和是否允许拒答等信息，可用于支撑对比实验、消融实验和重复运行一致性分析。

3. 固定对照实验结果。完成常规 RAG、常规 Agentic RAG 与 Task Graph Agentic RAG 的统一对比，并形成答案准确率、任务完成率、路由准确率、引用准确率、证据召回率、失败恢复率和多次运行一致性等实验表格，使不同方法的优势和不足能够直观呈现。

4. 消融实验与稳定性分析。通过去掉 Evidence Gate、去掉 Local Retry、去掉页面图像检索、去掉引用校验等消融实验，分析不同模块对复杂文档问答稳定性的贡献，并结合具体案例说明错误证据、检索失败和引用不稳定产生的原因。

5. 学习助手验证 Demo。完成一个轻量演示界面或命令行 Demo，用于展示任务图执行过程、检索证据、Evidence Gate 判断结果、局部重检过程和带引用的最终答案，使系统效果能够通过录屏或现场演示直观呈现。

6. 完整项目材料。形成开题报告、实验方案、系统设计说明、测试集标注说明、实验结果分析报告、答辩 PPT、演示视频或现场 Demo，为后续项目总结、答辩展示和成果复现提供完整支撑。

最终预期成果是证明：在复杂学习文档问答场景下，Task Graph 通过约束 workflows、验证节点证据和执行局部失败恢复，能够相较普通 RAG 和常规 Agentic RAG 提升任务完成率、引用准确率、失败恢复率和多次运行一致性，并在加入干扰文档后保持更强的抗干扰能力。通过系统原型、测试集、实验表格和案例分析，本课题希望说明 Task Graph 不只是流程编排方式，也是一种提高复杂文档问答可控性、可解释性和鲁棒性的有效方法。



## 参考文献

- [1] Lewis P, Perez E, Piktus A, Petroni F, Karpukhin V, Goyal N, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Advances in Neural Information Processing Systems 33. 2020.
- [2] Singh A, Ehtesham A, Kumar S, Khoei T T, Vasilakos A V. Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG[EB/OL]. arXiv:2501.09136, 2025.
- [3] Faysse M, Sibille H, Wu T, et al. ColPali: Efficient Document Retrieval with Vision Language Models[C]//International Conference on Learning Representations. 2025.
- [4] Yu S, Tang C, Xu B, et al. VisRAG: Vision-based Retrieval-augmented Generation on Multi-modality Documents[EB/OL]. arXiv:2410.10594, 2024.
- [5] Cho J, Lee S, Kim M, et al. M3DocRAG: Multi-modal Retrieval is What You Need for Multi-page Multi-document Understanding[EB/OL]. arXiv:2411.04952, 2024.
- [6] Dong Y, Hu X, Wang Z, et al. MMDocIR: Benchmarking Multimodal Retrieval for Long Documents[EB/OL]. arXiv:2501.08828, 2025.
- [7] Dong Y, Hu X, Wang Z, et al. Benchmarking Retrieval-Augmented Multimodal Generation for Document Question Answering[EB/OL]. arXiv:2505.16470, 2025.
- [8] Kweon S, Nam S, Lim H, Hong H, Choi E. A Large-Scale Real-World Evaluation of an LLM-Based Virtual Teaching Assistant[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics: Industry Track. Vienna: Association for Computational Linguistics, 2025: 850-864.
- [9] 余胜泉, 熊莎莎. 基于大模型增强的通用人工智能教师架构[J]. 开放教育研究, 2024, 30(1): 33-43.
- [10] 刘邦奇, 俞彦瑶, 王涛, 袁婷婷, 韩萌. 人工智能教育大模型: 体系架构与关键技术策略[J]. 开放教育研究, 2024, 30(5): 76-86.